

Exécution optimale des transactions financières avec l'apprentissage par renforcement

Ndjonkam Innocent
Université de Mons

Service de Mathématique et recherche opérationnelle

Directeur: Pr. Xavier SIEBERT, **Recherche opérationnelle**

Co-directeur: Pr. Matthieu SIMON, **Probabilités**

Année académique: **2025 - 2026**

Résumé

L'exécution optimale des transactions financières consiste à déterminer comment acheter ou vendre une grande quantité d'actifs tout en minimisant l'impact de cette transaction sur le marché, car peut causer une fluctuation défavorable des prix. Il s'agit d'un problème important dans les marchés financiers qui sont des environnements complexes et très difficiles à modéliser. Dans ce mémoire nous présentons un cadre de modélisation de ce problème basé sur un modèle d'apprentissage par renforcement : *optimisation de politique proximale*. Contrairement aux modèles de référence comme le modèle d'*Almgren-Chriss* qui utilisent des hypothèses simples de la dynamique des marchés pour obtenir des stratégies statiques, le modèle d'*optimisation de politique proximale* peut prendre des décisions d'exécution de transactions directement à partir des informations du marché sans faire des hypothèses préalables. Cette étude met alors en évidence le potentiel de l'apprentissage par renforcement par rapport au modèle d'*Almgren-Chriss* pour résoudre le problème d'exécution optimale des transactions financières.

Table des matières

1	MODÈLE D'ALMGREN-CHRISS	2
1.1	Formulation du modèle	2
1.1.1	Notation	2
1.1.2	Évolution du prix d'un actif financier	2
1.1.3	Coût d'exécution d'une stratégie	3
1.1.4	Impact de marché	3
1.2	Problème d'optimisation	4
1.3	Analyse du paramètre d'aversion au risque λ	5
2	ANALYSE DES DONNÉES LOBSTER	7
2.1	Base de données	7
2.1.1	Fichier <i>message</i>	7
2.2	Fichier <i>orderbook</i>	8
2.2.1	Analyse du cours des actions	9
3	MÉTHODOLOGIE ET RÉSULTATS	11
3.1	Architecture des modèles	11
3.1.1	Almgren & Chris	11
3.1.2	PPO + LSTM	12
3.2	Analyse des résultats	13
3.2.1	Comparaison des modèles	14
3.2.1.1	Performances sur les données de test	14
3.2.1.2	Analyse Statistique	17

Table des figures

1.1	Stratégies moyennes sur données AMZN Lobster	6
2.1	Message	9
2.2	Carnet d'ordre	9
2.3	Évolution du cours des actions	10
3.1	Récompenses	15
3.2	Distributions des récompenses	16
3.3	Stratégies moyennes	17

Liste des tableaux

2.1	Dimension des carnets d'ordres	9
3.1	Inventaire à ventre	14
3.2	Grille de recherche des hyperparamètres pour le modèle PPO+LSTM	14
3.3	Paramètres optimaux du PPO+LSTM	14
3.4	Comparaison des performances	18

INTRODUCTION

Supposons une entreprise européenne qui produit des articles pour les vendre dans le monde entier en dollars et paye ses salariés en euros. Elle se retrouve obligée de convertir la totalité de ses dollars en euros avant une certaine date. Cependant, étant donné que le taux d'échange dollar-euro varie, elle doit alors trouver une stratégie qui lui permet d'effectuer cette conversion de manière optimale si elle veut minimiser les pertes ou maximiser les gains. L'exécution optimale des transactions financières est la solution à ce problème car elle permet de répondre à une question qui semble simple mais extrêmement complexe en réalité :

comment acheter ou vendre une grande quantité d'actifs financiers au meilleur coût possible sans perturber excessivement le marché ?

Il s'agit d'un problème majeure dans les marchés financiers modernes et traditionnellement, la résolution de ce problème se fait grâce à des modèles mathématiques qui utilisent des hypothèses permettant de trouver un équilibre entre simplicité et applicabilité. Mais ces hypothèses simplifient parfois extrêmement le comportement des marchés financiers ce qui peut conduire à des solutions sous-optimales. À l'inverse, en voulant capturer toutes les caractéristiques réelles des marchés financiers, on aboutit à des modèles complexes qui sont presque impossibles à résoudre mathématiquement ou par approche computationnelle. De plus, ces dernières décennies les progrès technologiques ont fortement bouleversé les marchés financiers avec une forte quantité des données à récolter et traiter. Ceci a fortement révolutionner les techniques de traitement des données, de modélisation statistique et d'implémentation algorithmique. L'apprentissage par renforcement est alors une technique qui permet d'exploiter cette masse d'information sans faire d'hypothèses forte sur la dynamique des marchés. Il s'agit d'une méthode qui permet à un agent d'acquérir une connaissance de plus en plus améliorée du marché financier grâce à des interactions multiples avec celui-ci et enfin de prendre des décisions optimales.

Ce mémoire a donc pour objectif de fournir une présentation détaillée sur l'application du modèle d'*algorithme du modèle d'optimisation de la politique proximale* pour le problème d'exécution optimale des transactions en finance. Il s'agit d'un modèle d'apprentissage par renforcement proposé par OpenAI [14] qui alterne entre l'échantillonnage des données et l'optimisation d'une fonction objective. Nous présentons d'abord le modèle d'*Almgren-Chriss* [1] qui est un modèle mathématique constituant l'un des premiers piliers pour la résolution du problème d'exécution optimale. Le *modèle d'optimisation de la politique proximale* [7] sera mise en œuvre et comparé au modèle d'*Almgren-Chriss*. Cette comparaison se fera en déployant ces deux modèles sur des données financières réelles Lobster provenant du NASDAQ que l'on présentera.

Chapitre 1

MODÈLE D'ALMGREN-CHRISS

Dans ce chapitre nous allons présenter les travaux fondateurs de la littérature sur l'exécution optimale. Il s'agit de la modélisation d'*Almgren-Chriss* pour l'exécution optimale des ordres de marché qui consiste à déterminer la stratégie optimale de vente ou d'achat selon une certaine fonction objective.

Introduction: En finance de marché le prix d'un actif résulte des interactions entre les différents participants et de la liquidité disponible dans le carnet d'ordres. Lorsqu'un investisseur souhaite exécuter un ordre de grande taille, ses transactions influencent directement les prix, générant ce que l'on appelle un impact de marché. L'exécution d'une position importante ne peut alors être considérée comme neutre et doit être pensée de manière stratégique. Cette réalité soulève une problématique centrale : comment exécuter une position de vente ou d'achat via des ordres de marché de manière optimale ? Une exécution rapide permet de réduire l'exposition au risque de fluctuation des prix, mais entraîne un coût élevé lié à l'impact de marché. Une exécution progressive limite cependant cet impact, mais expose l'investisseur à l'incertitude sur l'évolution des prix future. Il en résulte un compromis fondamental entre coût d'exécution et risque qui est au cœur des travaux de *Dimitris Bertsimas et Andrew W. Lo [3]* puis approfondi par *Robert Almgren et Neil Chriss [1]* qui introduisent un cadre intégrant explicitement ce compromis. Dans ce chapitre nous présentons d'abord la formulation du modèle d'exécution optimale en décrivant l'évolution du prix d'un titre financier ainsi que la modélisation du coût d'exécution et du coût associé à une trajectoire de trading sous des hypothèses spécifiques sur les fonctions d'impact de marché. Nous étudions ensuite le problème d'optimisation correspondant en dérivant explicitement la solution qui permet de caractériser la stratégie d'exécution optimale.

1.1 Formulation du modèle

Ce modèle existe dans le cas continu et discret mais pour des raisons d'implémentation numérique, nous allons présenter uniquement le cas discret.

1.1.1 Notation

Nous considérons un trader qui possède une position notée Q qu'il souhaite liquider (vendre tous ses actions) durant un horizon de trading $[0, T]$. On suppose qu'il liquide cette position avec une trajectoire de trading $(q_0, \dots, q_N)$ durant les instants

$$0 = t_0 < t_1 < \dots < t_N = T.$$

q_k représente l'inventaire restant ou la quantité d'actifs restants à l'instant t_k avec $q_0 = Q$ et $q_N = 0$. Les intervalles $\{[t_{k-1}, t_k], k \in \{1, \dots, N\}\}$ de trading sont de longueurs $\tau = \frac{T}{N}$ pendant lesquels il vend des quantités $(n_k = q_{k-1} - q_k)_{k=1, \dots, N}$ d'actifs. À tout instant t_k on note S_k le cours de l'actif.

1.1.2 Évolution du prix d'un actif financier

À l'instant initial t_0 le cours de l'actif est de S_0 ce qui donne à notre position initiale une valeur de QS_0 , ce cours évolue selon un processus influencé principalement par la volatilité et l'impact de marché [1]

de la manière suivante :

$$S_{k+1} = S_k + \sigma\sqrt{\tau}\zeta_{k+1} - \tau g\left(\frac{n_{k+1}}{\tau}\right), \quad k \in \{0, \dots, N-1\}. \quad (1.1)$$

Avec σ qui représente la volatilité de l'actif, ζ_{k+1} un bruit aléatoire de moyenne nulle, de variance 1 et g la fonction d'impact permanent. Le terme $\sigma\sqrt{\tau}\zeta_{k+1}$ est appelé le risque de marché. Cependant durant les intervalles de trading, les ordres de vente du trader ne sont pas exécutés au prix du cours (1.1), car il devra aussi payer un coût d'exécution provenant de la liquidité du carnet d'ordres et donc le prix d'exécution de son ordre [1] est donné par :

$$\tilde{S}_{k+1} = S_k - h\left(\frac{n_{k+1}}{\tau}\right), \quad k \in \{0, \dots, N-1\}. \quad (1.2)$$

avec h qui représente la fonction d'impact temporaire.

1.1.3 Coût d'exécution d'une stratégie

Nous pouvons maintenant introduire la notion de coût d'exécution d'une stratégie $(q_0, \dots, q_N)$ qui n'est que le déficit de mise en œuvre IS avec pour prix initial S_0 et les prix d'exécution $(\tilde{S}_{k+1})_{k=0, \dots, N-1}$:

$$C(q_0, \dots, q_N) = QS_0 - \sum_{k=1}^N n_k \tilde{S}_k = -IS(n_0, \dots, n_N) \quad (1.3)$$

Proposition 1.1.1 : Le coût d'exécution étant une variable aléatoire, notre objectif sera alors de trouver une stratégie de vente optimale $(q_0^*, \dots, q_N^*)$ qui minimise en moyenne ce coût en tenant compte de sa variabilité. On a alors :

$$\mathbb{E}(C(q_0, \dots, q_N)) = \sum_{k=1}^N \tau q_k g\left(\frac{n_k}{\tau}\right) + \sum_{k=1}^N n_k h\left(\frac{n_k}{\tau}\right) \quad (1.4)$$

$$\mathbb{V}ar(C(q_0, \dots, q_N)) = \sigma^2 \sum_{k=1}^N \tau q_k^2 \quad (1.5)$$

Le terme $\sum_{k=1}^N \tau q_k g\left(\frac{n_k}{\tau}\right)$ est le montant que l'on perd au final à cause de l'impact permanent de notre stratégie qui consiste à conserver q_k actifs et vendre n_k durant les intervalles de temps $[t_{k-1}, t_k]$. Le terme $\sum_{k=1}^N n_k h\left(\frac{n_k}{\tau}\right)$ est le montant que l'on perd au final à cause de l'impact temporaire qui réduit précisément le gain total à chaque instant k en fonction de la quantité d'actif n_k qui est vendue. On constate alors qu'en moyenne le coût d'une stratégie de trading n'est que le montant total qui est perdue à cause des impacts permanent et temporaire de cette stratégie.

1.1.4 Impact de marché

Il est temps de se focaliser sur les expressions des fonctions qui définissent l'impact permanent et l'impact temporaire afin de déduire mathématiquement une stratégie optimale. En effet, lorsque l'ordre d'un trader est exécuté sur le marché, il modifie l'équilibre entre l'offre et la demande en consommant la liquidité du carnet d'ordres et en donnant des informations au marché ce qui pousse les autres acteurs à des modifications. Cet ordre aura d'abord un impact temporaire proportionnel à la taille de l'ordre et est défini par une fonction linéaire :

$$h\left(\frac{n_k}{\tau}\right) = \epsilon \text{sign}(n_k) + \frac{\eta}{\tau} n_k. \quad (1.6)$$

Avec η qui représente un paramètre de liquidité.

L'impact permanent est aussi défini par une fonction linéaire :

$$g(n) = \gamma n. \quad (1.7)$$

Avec γ qui est un paramètre d'information dont la valeur est déduite sur le prix à chaque fois qu'un actif est vendu.

Le choix de fonctions linéaires est très important pour avoir une structure quadratique au problème d'optimisation et ainsi déterminer les solutions optimales plus simplement.

Proposition 1.1.2 : Avec ces fonctions d'impact linéaires le coût moyen (1.4) devient :

$$\mathbb{E}(C(q_0, \dots, q_N)) = \frac{1}{2}Q^2 + \epsilon \sum_{k=1}^N |n_k| + \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N n_k^2. \quad (1.8)$$

Avec $\tilde{\eta} = \eta - \frac{1}{2}\gamma\tau$.

1.2 Problème d'optimisation

L'objectif de l'exécution optimale est de trouver des stratégies qui reposent sur un compromis fondamental. D'une part, avoir une stratégie dont la vitesse de négociation permet de limiter l'impact de marché qui est une influence négative des ordres sur les prix, ce qui conduit à une réduction des coûts d'exécution. Lorsque la quantité d'actif à vendre est grande, une exécution progressive et lente dans le temps permet de mieux se fondre dans la liquidité disponible en évitant de révéler de manière trop brutale son intention de trading. D'autre part, une exécution trop lente expose à un risque (variance) accru lié aux fluctuations exogènes des prix. Par exemple dans un marché volatil, retarder l'exécution peut entraîner des pertes importantes si les prix évoluent défavorablement. Accélérer la vitesse de négociation permet alors de réduire cette incertitude tout en causant un impact de marché plus élevé.

L'objectif est donc de trouver des stratégies qui équilibrent minimisation du coût et maîtrise du risque en fonction de paramètres tels que la liquidité du marché, la volatilité des prix, l'horizon temporel de trading ou encore l'aversion au risque du trader. *Almgren et Chriss* proposent alors de trouver une stratégie qui a un coût moyen minimal en fonction d'un niveau de risque (variance) maximal $V_\star \geq 0$ fixé :

$$\min_{sc: \text{Var}(C(q)) \leq V_\star} \mathbb{E}(C(q)) = \min_{sc: \text{Var}(C(q)) \leq V_\star} \left\{ \frac{\gamma}{2}Q^2 + \sum_{k=1}^N \epsilon |q_{k-1} - q_k| + \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N (q_{k-1} - q_k)^2 \right\}. \quad (1.9)$$

L'ensemble $\{(q_0, \dots, q_N) : \text{Var}(C(q)) \leq V_\star\} = \left\{ (q_0, \dots, q_N) : \sum_{k=1}^N q_k^2 \leq \frac{V_\star}{\tau\sigma^2} \right\}$ est convexe car il s'agit d'une sphère. De plus, $\mathbb{E}(C(q))$ est strictement convexe si $\tilde{\eta} > 0$. En effet $\frac{\gamma}{2}Q^2$ est une constante, $q \mapsto \epsilon \sum_{k=1}^N |q_{k-1} - q_k|$ est convexe car la fonction valeur absolue est convexe et comme la fonction $x \mapsto x^2$ est convexe, alors $q \mapsto \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N (q_{k-1} - q_k)^2$ est convexe si $\tilde{\eta} > 0$.

Il existe alors une unique solution $q_\star(V_\star)$ qui dépend du seuil $V_\star$ pour le problème (1.9). Ceci permet de dire que l'ensemble des solutions optimales du problème (1.9) peut être paramétré par un niveau du risque du coût des transaction.

Nous pouvons introduire le multiplicateur de Lagrange λ pour résoudre le problème (1.9) et on obtient :

$$\min_{q=(q_0, \dots, q_N)} \{\mathbb{E}(C(q)) + \lambda \text{Var}(C(q))\} \quad (1.10)$$

Chaque trajectoire de trading $(q_0, \dots, q_N)$ fournit un coût attendu $\mathbb{E}(C(q_0, \dots, q_N))$ et une variance de ce coût $\text{Var}(C(q_0, \dots, q_N))$ ce qui fait de cette trajectoire un point $(\mathbb{E}(C(q)), \text{Var}(C(q)))$. Varier le multiplicateur de Lagrange λ permet de représenter l'ensemble des solutions optimales dans un plan. Sur le point de vue financier, un trader voudra toujours une stratégie qui minimise le coût attendu mais s'il est très prudent et averti au risque, il liquide rapidement sa position. Par contre s'il est moins sensible au risque et accepte plus d'incertitude alors liquide sa position plus lentement. Ceci permet de dire qu'une stratégie optimale est obtenue en fonction du niveau d'aversion au risque λ du trader. Le multiplicateur de Lagrange λ permet de mesurer l'aversion au risque du trader. En d'autres termes, il pénalise la variance par rapport au coût espéré.

Proposition 1.2.1 : Solution au problème d'optimisation

La fonction $U(q) = \mathbb{E}(C(q)) + \lambda \text{Var}(C(q))$ est une fonction convexe comme somme de fonction convexe et nous cherchons une solution dans l'ensemble :

$$\mathcal{C} = \left\{ (q_0, \dots, q_N) : \sum_{k=1}^N (q_{k-1} - q_k) = Q, q_0 = Q, q_N = 0 \right\}$$

Ainsi pour tout λ fixé il existe une unique solution dans $\mathcal{C}$ qui minimise U :

$$q_j = \frac{\sinh(\kappa(T - t_j))}{\sinh(\kappa T)} Q; \quad j = 0, \dots, N \quad (1.11)$$

dont la liste de liquidation est :

$$n_j = \frac{2 \sinh\left(\frac{1}{2}\kappa\tau\right)}{\sinh(\kappa T)} \cosh\left(\kappa\left(T - t_{j-\frac{1}{2}}\right)\right) Q; \quad j = 1, \dots, N \quad (1.12)$$

1.3 Analyse du paramètre d'aversion au risque λ

Le problème d'optimisation (1.10) peut être considéré comme un problème de contrôle stochastique moyenne-variance où λ est un paramètre de pénalisation de la variance. Dans ce problème on peut constater d'une part que la minimisation de la moyenne $\mathbb{E}(C(q))$ favorise les stratégies avec petits volumes régulièrement répartis dans le temps. En effet, trouver la stratégie $(q_0, \dots, q_N)$ (suite décroissante) dans $\mathcal{C}$ qui minimise :

$$\begin{aligned} \mathbb{E}(C(q)) &= \frac{\gamma}{2} Q^2 + \sum_{k=1}^N \epsilon |q_{k-1} - q_k| + \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N (q_{k-1} - q_k)^2 \\ &= \frac{\gamma}{2} Q^2 + \epsilon \sum_{k=1}^N (q_{k-1} - q_k) + \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N (q_{k-1} - q_k)^2 \\ &= \frac{\gamma}{2} Q^2 + \epsilon Q + \frac{\tilde{\eta}}{\tau} \sum_{k=1}^N (q_{k-1} - q_k)^2 \end{aligned}$$

revient simplement à trouver $(q_0, \dots, q_N)$ qui minimise $\sum_{k=1}^N (q_{k-1} - q_k)^2 = \sum_{k=1}^N n_k^2$. Mais d'après la relation :

$$\left(\frac{1}{N} \sum_{k=1}^N n_k \right)^2 \leq \frac{1}{N} \sum_{k=1}^N n_k^2,$$

on déduit que $\frac{1}{N} \left(\sum_{k=1}^N n_k \right)^2 \leq \sum_{k=1}^N n_k^2$ avec égalité si $n_1 = n_2 = \dots = n_N = \frac{Q}{N}$. Donc la stratégie qui minimise $\mathbb{E}(C(q))$ est la stratégie associée à $n_1 = n_2 = \dots = n_N = \frac{Q}{N}$ avec pour trajectoire :

$$q_k = (N - k) \frac{Q}{N}$$

qu'on appelle stratégie des prix moyens pondérés dans le temps ou stratégie TWAP (time-weighted average price).

D'autre part, la minimisation de la variance favorise les stratégies rapides car la stratégie $(q_0, \dots, q_N)$ dans $\mathcal{C}$ qui minimise $\text{Var}(C(q)) = \tau \sigma^2 \sum_{k=1}^N q_k^2$ est la stratégie associée à $n_1 = Q, n_2 = \dots = n_N = 0$ avec pour trajectoire :

$$q_1 = 0 = q_2 = \dots = q_N = 0$$

qui nous donne une variance minimale $\text{Var}(C(q)) = 0$.

On peut constater que dans notre problème d'optimisation (2.10), plus λ est petit, plus le problème est dominé par l'impact de la stratégie. Alors que plus λ est grand plus le problème est dominé par le risque de variation des prix. On peut le confirmer sur le graphe suivant :




FIGURE 1.1 – Stratégies moyennes sur données AMZN Lobster

Le graphe précédent nous montre les stratégies moyennes $(q_0, \dots, q_N)$ fournies par le modèle d'Almgren-Chriss sur 2000 épisodes (expériences) successives ayant chacun un horizon de trading de dix pas de temps pendant lesquels il faut vendre un inventaire $Q = 50$ unités. On peut constater que plus λ est grand plus la stratégie est rapide et lorsque λ est proche de 0 on obtient la stratégie TWAP.

Conclusion: Dans ce chapitre *Almgren et Chriss* nous présente un modèle qui permet d'obtenir la stratégie optimale pour l'exécution d'une position en tenant compte de l'aversion au risque du trader. Cependant cette stratégie est statique, déterminée avant le début des transactions et ne tient pas compte des informations qui arriveront progressivement. De plus, cette stratégie optimale est déterminée mathématiquement grâce à des hypothèses fortes concernant l'évolution des prix. Les fonctions d'impact de marché ne sont pas toujours linéaires, ni convexes. L'apprentissage par renforcement devient alors une solution idéale pour le problème d'exécution optimale, car il permet à un agent de comprendre la dynamique du marché financier avec peu d'hypothèses.

Chapitre 2

ANALYSE DES DONNÉES LOBSTER

Introduction: Tout au long de notre implémentation nous utiliserons les bases de données provenant du site web <https://php.lobsterdata.com/info/DataSamples.php> qui sont extrêmement riches et très utilisés dans la recherche sur le trading haute fréquence. Depuis 2013, LOBSTER fournit à la communauté académique des données permettant de reconstituer l'historique des carnets d'ordres à cours limité pour tous les actifs cotés sur le NASDAQ. Ces données couvrent tous les jours de bourse du NASDAQ à partir du 6 janvier 2009 jusqu'à avant-hier. Ces données nous permettront d'évaluer et comparer nos modèles qui ont été présentés dans les chapitre précédents. Ceci nous oblige à d'abord effectuer une analyse afin de comprendre les paramètres de microstructure de ces données.

2.1 Base de données

Il s'agit des données de carnet d'ordres à cours limité pour la journée du 21 juin 2012 qui couvrent exactement la session journalière du NASDAQ entre 09 :30 et 10 :30 (heure de New York). Chaque base de données permet de reconstituer complètement l'historique d'un carnet d'ordres à cours limité à partir de deux fichiers :

- 1- un fichier *message* qui permet de préciser les évènements du marché qui ont conduits à une modification du carnet d'ordre.
- 2- un fichier *orderbook* qui décrit l'état du carnet d'ordre après chaque événement provenant du fichier *message*

2.1.1 Fichier *message*

Il s'agit d'un fichier de type csv contenant une matrice de taille $N \times 6$ (N lignes et 6 colonnes) dont chaque ligne représente un événement d'ordre à cours limité ayant entraîné la modification du carnet et les colonnes sont :

- 1- **Time** : qui représente le temps en seconde après minuit avec une précision qui peut aller de quelques millisecondes jusqu'aux nanosecondes en fonction de la période demandée. Par exemple 34200 secondes après minuit représentent 09h30.
- 2- **Type** : qui représente le type d'ordre émis :
 - soumission d'un nouvel ordre limité : 1.
 - Suppression ou annulation partielle d'un ordre limité : 2.
 - Suppression total d'un ordre limité : 3.
 - Exécution d'un ordre limité visible : 4.
 - Exécution d'un ordre limité caché : 5.
 - Indicateur de suspension des transactions (pause du marché) : 6.
- 3- **Order ID** : Numéro de référence unique de l'ordre qui est affecté selon le flux de l'ordre
- 4- **Size** : qui représente le nombre d'actions de l'ordre

5- **Price** : qui est représenté en Dollar multiplier par 10000. Par exemple une action avec un prix réel de 56.17\$ sera donné par 561700

6- **Direction** : -1 représente un ordre limité de vente et 1 représente un ordre limité d'achat.

Il est important de noter que l'exécution d'un ordre de vente (respectivement d'achat) limite est une transaction initiée par un acheteur (respectivement, un vendeur), c'est-à-dire une transaction d'achat (respectivement, vente).

2.2 Fichier *orderbook*

Il s'agit d'un fichier de type csv contenant une matrice de N lignes et $4 \times level$ colonnes où *level* est le niveau de profondeur du carnet. Chaque ligne précise l'état complet du carnet d'ordre et les colonnes représentent chaque niveau de profondeur $i \in \{1, 2, \dots, level\}$:

- *Ask Price i* : prix de vente au niveau i .
- *Ask Size i* : quantité d'actifs à vendre au prix unitaire de *Ask Price i*.
- *Bid Price i* : prix d'achat au niveau i .
- *Bid Size i* : quantité d'actifs à acheter au prix unitaire de *Bid Price i*.

Donc pour $level = 10$ niveaux de profondeur, on a 40 colonnes et chaque niveau i occupe 4 colonnes. Si pour un niveau i on a **Unoccupied Price Levels**, alors le niveau n'existe pas et LOBSTER remplit avec :

- *Ask price i* : 9999999999
- *Bid price i* : -9999999999
- *Ask Size i* et *Bid Size i* : 0

Les fichiers *message* et *orderbook* sont alignés ligne par ligne :

- la ligne k dans *message file* correspond à un événement d'ordre à cours limité du marché.
- La ligne k dans *orderbook file* correspond à l'état du marché après cet événement.

On peut l'observer sur l'exemple suivant :

	Time	Type	OrderID	Size	Price	TradeDirection
0	34200.017460	5	0	1	2238200	-1
1	34200.189608	1	11885113	21	2238100	1
2	34200.189608	1	3911376	20	2239600	-1
3	34200.189608	1	11534792	100	2237500	1
4	34200.189608	1	1365373	13	2240000	-1
5	34200.189608	1	11474176	2	2236500	1
6	34200.189608	1	1847685	100	2240000	-1
7	34200.189608	1	3920359	15	2236000	1
8	34200.189608	1	3578212	4	2240000	-1
9	34200.189608	1	4632045	100	2235000	1

FIGURE 2.1 – Message

	ASKp1	ASKs1	BIDp1	BIDs1	ASKp2	ASKs2	BIDp2	BIDs2	ASKp3	ASKs3	...	BIDp8	BIDs8	ASKp9	ASKs9	BIDp9	BIDs9	ASKp10	ASKs10	BIDp10	BIDs10
0	223.95	100	223.18	100	223.99	100	223.07	200	224.00	220	...	220.25	5000	229.43	100	220.20	100	229.80	100	218.97	100
1	223.95	100	223.81	21	223.99	100	223.18	100	224.00	220	...	220.40	100	229.43	100	220.25	5000	229.80	100	220.20	100
2	223.95	100	223.81	21	223.96	20	223.18	100	223.99	100	...	220.40	100	226.77	100	220.25	5000	229.43	100	220.20	100
3	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	221.30	4000	226.77	100	220.40	100	229.43	100	220.25	5000
4	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	221.30	4000	226.77	100	220.40	100	229.43	100	220.25	5000
5	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	222.62	100	226.77	100	221.30	4000	229.43	100	220.40	100
6	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	222.62	100	226.77	100	221.30	4000	229.43	100	220.40	100
7	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	223.00	10	226.77	100	222.62	100	229.43	100	221.30	4000
8	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	223.00	10	226.77	100	222.62	100	229.43	100	221.30	4000
9	223.95	100	223.81	21	223.96	20	223.75	100	223.99	100	...	223.04	100	226.77	100	223.00	10	229.43	100	222.62	100

FIGURE 2.2 – Carnet d'ordre

La ligne numéro 0 du carnet d'ordres correspond à l'état du marché après l'évènement de la ligne 0 de *Message* qui est l'exécution d'un ordre limité caché (**Type** = 5) de vente (**Direction** = -1) d'une action (**Size** = 1) au prix unitaire de 223.82\$.

La ligne numéro 1 correspond à l'état du marché après soumission (**Type** = 1) d'un nouvel ordre limité d'achat (**Direction** = 1) de 21 actions (**Size** = 21) au prix unitaire de 223.81\$. Cette ordre d'achat devient alors la meilleure offre d'achat car la précédente meilleure offre était au prix de 223.18\$. Les autres ordres d'achat sont automatiquement décalés d'un niveau profondeur vers le bas.

La tableau suivant nous permet de voir les dimensions des carnets d'ordres de nos titres :

Titres	N : nombres de lignes	Niveau de profondeur
<i>AMZN</i>	269748	10
<i>AAPL</i>	400391	10
<i>GOOGL</i>	147916	10
<i>INTC</i>	624040	10
<i>MSFT</i>	668765	10

TABLE 2.1 – Dimension des carnets d'ordres

2.2.1 Analyse du cours des actions

L'analyse de la volatilité permettra de connaître l'intensité des fluctuations du prix de nos différents titres au cours du temps. Nous commençons d'abord par visualiser le cours des actions :




FIGURE 2.3 – Évolution du cours des actions

On constate que pendant ce jour les cours étaient décroissants jusqu'à la fin de session (10 : 30) pour tous les titres. Ceci implique que la meilleure stratégie pour un trader ce jour était en général d'être averti au risque et liquider sa position le plus vite lorsqu'il rentre sur le marché de ces titres. Il est vrai que pour *AMZN* et *AAPL* on a une légère hausse au début de la session mais avant le milieu de la journée on a une décroissance jusqu'à la fin.

Conclusion: Ce chapitre nous a permis de comprendre la microstructure du marché des titres que nous utiliserons pour comparer nos modèles dans la suite. En fonction de cette analyse nous pouvons fixer certains paramètres à savoir l'horizon temporelle et la quantité d'actions à vendre pour ces modèles sur le marché de chaque titre.

Chapitre 3

MÉTHODOLOGIE ET RÉSULTATS

Introduction: Après avoir présenté les fondements théoriques de l'exécution optimale ainsi que le cadre de l'apprentissage par renforcement en particulier le modèle d'*optimisation de la politique proximale (PPO)*, nous allons passer à une mise en œuvre concrète de nos modèles dans un contexte de marché réaliste. Les modèles analytiques tels que celui de *Robert Almgren et Neil Chriss* [1] reposent sur des hypothèses simples qui limitent leur capacité à capturer la complexité des carnets d'ordres réels. Dans ce contexte une question centrale se pose : comment exploiter les données de marché financiers électroniques et les techniques d'apprentissage par renforcement pour construire une stratégie d'exécution optimale adaptée à un environnement financier réaliste et dynamique ? L'enjeu est alors de modéliser correctement l'interaction entre un agent et le carnet d'ordres tout en définissant une fonction de récompense pertinente permettant d'orienter l'apprentissage vers des stratégies efficaces. Ce chapitre a pour objectif de présenter la méthodologie adoptée ainsi que les résultats obtenus pour une comparaison des modèles *Almgren-Chriss* et d'*optimisation de la politique proximale (PPO)*. L'objectif de chaque modèle est de vendre une quantité d'action durant un certains horizons temporel. Nous commençons par formuler le problème d'exécution optimale comme un processus de décision markovien, en définissant précisément l'espace d'états, l'espace d'actions et les probabilités de transition à partir des données de carnet d'ordres LOBSTER. Nous décrivons ensuite le mécanisme d'exécution des ordres et la construction de la fonction de récompense, qui intègre à la fois le déficit de mise en œuvre et le risque lié à l'inventaire restant. Nous présentons enfin les résultats expérimentaux obtenus et analysons les performances des modèles dans cet environnement.

3.1 Architecture des modèles

Nos modèles sont conçus pour prendre des décisions (ordres de marché) de vente après chaque mise à jour du carnet d'ordres via le fichier *Message*. Un épisode qui est une partie correspondante à dix décisions ($T = 10$) prises par un modèle ce qui représente dix lignes du carnet d'ordre traversées par le modèle, ensuite la partie suivante se fera sur les dix lignes qui suivent jusqu'à atteindre le nombre de partie souhaité ou la dernière ligne du carnet d'ordres. À la fin de chaque partie, l'agent reçoit une récompense (*IS*) qui est le coût moyen de sa stratégie et on pourra comparer les récompenses des différents modèles. Nous présentons alors le fonctionnement spécifique de chaque modèle ainsi que leur algorithme.

3.1.1 Almgren & Chris

Pour le premier épisode, la stratégie optimale est calculée avec les paramètres σ , η et γ aléatoires. Ensuite à partir du deuxième épisode, les données du carnet d'ordres de l'épisode précédent sont utilisées pour l'estimation de ces paramètres. À partir de ces données la volatilité σ et le spread sont alors calculés. Le spread moyen fournit une mesure directe du coût de transaction et les volumes disponibles sur plusieurs niveaux du carnet permettent d'obtenir une approximation de la liquidité globale. Les paramètres d'impact de marché temporaire η et permanent γ , sont ensuite approximés en fonction du ratio entre le spread moyen et le volume moyen :

$$\eta = \frac{\text{spread moyen}}{0.01 \cdot \text{volume moyen}}, \quad \gamma = \frac{\text{spread moyen}}{0.1 \cdot \text{volume moyen}}$$

traduisant l'idée qu'un marché liquide réduit l'impact des ordres. Cette étape constitue une adaptation du modèle théorique d'*Almgren-Chriss* à des données de microstructure [12].

À partir de ces paramètres le modèle calcule une trajectoire optimale de liquidation, qui définit la quantité d'actifs à vendre à chaque instant.

Algorithm 1 Adaptive Almgren-Chriss Execution on LOBSTER Data

Entrée : LOB, inventaire initial X_0 , horizon T , nombre d'épisodes N , aversion du risque λ

```

1: pour  $ep = 1$  à  $N$  faire
2:   Calculer les paramètres du modèle :  $\sigma, \eta$  and  $\gamma$ 
3:    $\tau \leftarrow 1, IS \leftarrow 0$ 
4:    $\tilde{\eta} \leftarrow \eta - \frac{1}{2}\gamma\tau$ 
5:    $\kappa \leftarrow \frac{1}{\tau} \cosh^{-1} \left( 1 + \frac{1}{2} \frac{\lambda\sigma^2}{\tilde{\eta}} \tau^2 \right)$ 
6:   pour  $t = 0$  to  $T$  faire
7:     Si  $\kappa = 0$  alors
8:        $x_t \leftarrow X_0 (1 - \frac{t}{T})$ 
9:     Sinon
10:       $x_t \leftarrow \frac{\sinh(\kappa(T-t))}{\sinh(\kappa T)} X_0$ 
11:    Fin si
12:    Executer  $v_t \leftarrow x_{t-1} - x_t$ 
13:    Observer coût de transaction  $r_t = v_t(p_t - p_0)$ 
14:     $IS \leftarrow IS + r_t$ 
15:  fin pour
16:  Retourner  $IS$ 
17: fin pour
```

Nous allons utiliser deux modèles *AC* qui ne sont différents que par le risque d'aversion λ :

- *TWAP* qui est un *AC* avec pour risque d'aversion $\lambda = 0$
- un autre modèle *AC* avec pour risque d'aversion $\lambda = 9$

3.1.2 PPO + LSTM

Il s'agit d'une architecture d'*optimisation de la politique proximale* séquentielle combinant un réseau de neurone entièrement connecté et un réseau LSTM. Le réseau de neurone entièrement connecté est constitué d'une couche d'entrée de 25 Neurones correspondant à la dimension d'un états, Suivie d'une activation *ReLU*. Ensuite on a une couche de sortie de 128 Neurones suivie d'une activation *ReLU*. La sortie de ce réseau est concaténée avec deux variables supplémentaires correspondant à l'action précédente et à la récompense précédente. Ce vecteur est enfin transmis à un réseau LSTM afin de modéliser l'impact des actions passées sur l'évolution du carnet d'ordres. La représentation produite par le LSTM alimente ensuite deux réseaux de neurones distincts. Le premier correspond à l'*Acteur*, composé de deux couches linéaires représentant respectivement la moyenne et le logarithme de l'écart-type d'une distribution gaussienne. Cette distribution paramétrise la politique aléatoire utilisée pour sélectionner les actions. Le second réseau correspond au *Critique* qui estime la fonction de valeur de l'état à l'aide d'une couche linéaire. L'apprentissage est réalisé à l'aide de l'algorithme *optimisation de la politique proximale (PPO)* :

Algorithm 2 PPO + LSTM pour l'exécution optimale

```
1: Exploration
2: Initialiser les paramètres du réseau  $\theta$ ,  $IS = 0$ 
3: Initialiser le buffer  $\mathcal{D}$ 
4: pour chaque épisode faire
5:   Initialiser l'état  $s_0$ 
6:   pour  $t = 0, \dots, T$  faire
7:      $a_{-1} \leftarrow 0, reward_{-1} \leftarrow 0$ 
8:     Encoder  $s_t$  via un réseau de neurone  $f_{FC} : x_t = f_{FC}(s_t)$ 
9:     Construire  $z_t = [x_t, a_{t-1}, reward_{t-1}]$ 
10:    Passer dans le LSTM :  $h_t = \text{LSTM}(z_t)$ 
11:    Calculer la politique :
                                
$$\mu_t, \sigma_t = \pi_\theta(h_t)$$

12:    Échantillonner action :
                                
$$a_t \sim \mathcal{N}(\mu_t, \sigma_t)$$

13:    Exécuter  $a_t$ , observer  $reward_t, s_{t+1}$  et
14:    Stocker transition dans  $\mathcal{D}$ 
15:  fin pour
16:  Calculer les avantages  $A_t$ 
17:  Calculer les récompenses du modèle  $R_t$ 
18:  Calculer  $IS$ 
19:  Exploitation
20:  pour plusieurs epochs faire
21:    Calculer ratio :
                                
$$r_t = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$$

22:    Loss acteur :
                                
$$L^{\text{actor}} = -\mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

23:    Loss critique :
                                
$$L^{\text{critic}} = \mathbb{E}[(R_t - V(s_t))^2]$$

24:    Mettre à jour  $\theta$ 
25:  fin pourRetourner  $IS$ 
26: fin pour
```

3.2 Analyse des résultats

Nos modèles ont été entraînés sur des données de carnet d'ordres LoBster de cinq titres financiers à savoir : Amazone, Apple, Google, Intel et Microsoft. L'entraînement du *PPO* a utilisé 70% de chaque carnet d'ordre correspondant à une période allant de 09 : 30 à 10 : 12, puis on a validé nos modèles d'apprentissage par renforcement sur 20% de données (10 : 12 à 10 : 24), enfin on teste tous les modèles sur les données restantes (10 : 24 à 10 : 30).

Les épisodes sont réalisées sur des fenêtres glissantes du carnet d'ordres et chaque épisode dure un horizon de trading qui correspond au nombre d'ordre de vente émis sur le marché par un modèle pour liquider totalement sa position. Pendant chaque épisode nos modèles émettent des ordres de vente au marché après chaque mise à jour du carnet, puis on enregistre la récompense cumulée (IS) et la stratégie. La comparaison des modèles se fera sur la courbe des récompenses IS de tous les épisodes, les statistiques provenant de ces récompenses et sur la stratégie moyenne par épisode. Afin de tenir en compte de la liquidité de chaque titre financier, nous avons fixé différents inventaires à liquider :

titre financier	inventaire	Horizon de trading
AMAZONE (<i>AMZN</i>)	10	10
APPLE (<i>AAPL</i>)	20	10
GOOGLE (<i>GOOG</i>)	10	10
INTEL (<i>INTC</i>)	80	10
MICROSOFT (<i>MSFT</i>)	260	10

TABLE 3.1 – Inventaire à ventre

Dans un premier temps nous allons entrainer et optimiser un modèle PPO + LSTM sur chaque base de données, ensuite nous allons utiliser les plus performants pour une comparaison avec le modèle d'*Almgren – Chriss* (*AC*).

3.2.1 Comparaison des modèles

Sur chaque base de données nous avons d'abord optimiser les modèles RL en faisant varier nos hyperparamètres sur les valeurs suivantes :

Hyperparamètres	Valeurs
Taux d'apprentissage (<i>lr</i>)	$\{10^{-5}, 3 \times 10^{-5}, 10^{-4}\}$
Paramètre GAE (λ)	$\{0.93, 0.95, 0.97\}$
Taille de batch	$\{32, 64\}$

TABLE 3.2 – Grille de recherche des hyperparamètres pour le modèle PPO+LSTM

ce qui nous donne 18 combinaisons qui seront utilisées pour entrainer 18 modèles *PPO + LSTM*, ensuite nous allons comparer chaque modèle aux modèles *AC* et *TWAP* pour enfin garder celui qui aura les meilleures performances. Pour chaque base de données nous obtenons les paramètres optimaux suivants :

titre financier	lr	λ	Taille de batch
AMAZONE (<i>AMZN</i>)	3×10^{-5}	0.97	32
APPLE (<i>AAPL</i>)	3×10^{-5}	0.93	32
GOOGLE (<i>GOOG</i>)	3×10^{-5}	0.93	64
INTEL (<i>INTC</i>)	3×10^{-5}	0.97	64
MICROSOFT (<i>MSFT</i>)	3×10^{-5}	0.95	64

TABLE 3.3 – Paramètres optimaux du PPO+LSTM

3.2.1.1 Performances sur les données de test

La visualisation des récompenses (*IS*) moyennes nous permet de tirer de nombreuses interprétations en liens avec les caractéristiques de la microstructure du marché de chaque titre financier. Voici la visualisation des récompenses moyennes obtenues par les modèles sur toutes les bases de données de test :



FIGURE 3.1 – Récompenses

Ces courbes de récompenses montrent d'abord que les stratégies des trois modèles suivent globalement les mêmes tendances du marché de chaque titre, ce qui nous indique que les caractéristiques microstructurales influencent beaucoup les récompenses. On peut aussi voir que le modèle PPO+LSTM utilise des stratégies plus profitables et reste généralement au dessus des modèles TWAP et AC. Le modèle PPO+LSTM arrive donc à mieux s'adapter à la dynamique du carnet d'ordre. Il est aussi important de noter que les stratégies de nos modèles ne sont pas profitables sur le marché des titres *INTC* et *MSFT* car les récompenses gardent énormément des valeurs en dessous de 0. Sur le le marché des titres *GOOG*, la stratégie de l'agent PPO+LSTM reste le cas le plus profitable.

L'analyse des distributions de ces récompenses nous montrent un déplacement de la distribution du PPO+LSTM vers la droite avec une forte présence des récompenses positives par rapport aux modèles TWAP et AC sur les données *AMZN*, *AAPL* et *GOOGL* :



FIGURE 3.2 – Distributions des récompenses

Ceci indique que l'agent PPO+LSTM adopte des stratégies profitables sur de nombreuses épisodes.

Les trajectoires moyennes d'inventaire montrent une grande différence entre les modèles. Les modèles *TWAP* et *AC* adoptent des stratégies qui réduisent progressivement l'inventaire jusqu'à la dernière décision ce qui est conforme à la formulation théorique. *TWAP* réduit l'inventaire de manière linéaire tandis que le modèle *AC* adopte une liquidation plus agressive au début à cause de son risque averse qui vaut 9.




FIGURE 3.3 – Stratégies moyennes

Mais l'agent PPO+LSTM liquide pratiquement la totalité de sa position dès le premier instant. Cette stratégie très agressive nous indique que l'agent considère le risque de réduire progressivement l'inventaire comme étant supérieur à l'impact d'une liquidation rapide. Cette stratégie de l'agent peut s'expliquer par une forte liquidité disponible aux meilleurs niveaux, une profondeur importante du carnet d'ordres ou encore d'une résilience rapide du carnet après exécution des gros ordres de marché. On remarque aussi que sur les titres *AAPL* et *GOOGL* le modèle *AC* arrive à vendre une grande quantité de son inventaire dès les débuts, ce qui suggère que ce modèle est relativement bien adapté à la microstructure de ces titres.

3.2.1.2 Analyse Statistique

Pour une comparaison plus approfondie nous réalisons une statistique analyse statistique des performances de nos modèles. Pour cette analyse nous allons effectuer sur tous les titres une statistique des récompenses de l'agent par épisode, les différences des récompenses par épisode de l'agent et des autres modèles :

$$\Delta_{agent-TWAP} = IS_{agent} - IS_{TWAP}, \quad \Delta_{agent-AC} = IS_{agent} - IS_{AC}.$$

Nous allons aussi voir le nombre d'épisodes où l'agent a une meilleure stratégie que celles des autres modèles ainsi que la moyenne des gains et des pertes par rapport aux autres modèles :

$$\mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-TWAP} > 0], \quad \mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-AC} > 0]$$

et

$$\mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-TWAP} < 0], \quad \mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-AC} < 0].$$

Pour finir nous allons observer aussi le ratio de gain-perte (Gain-Loss ration) :

$$GLR_{agent-TWAP} = \frac{\mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-TWAP} > 0]}{\mathbb{E}[\Delta_{agent-TWAP} \mid \Delta_{agent-TWAP} < 0]}. \quad (3.1)$$

et

$$GLR_{agent-AC} = \frac{\mathbb{E}[\Delta_{agent-AC} \mid \Delta_{agent-AC} > 0]}{\mathbb{E}[\Delta_{agent-AC} \mid \Delta_{agent-AC} < 0]}. \quad (3.2)$$

Tous ces résultats se résument dans le tableau suivant :

Metric	AMZN	AAPL	GOOGL	INTC	MSFT
Récompense de l'agent					
Moyenne	-0.011	-0.015	0.008	-0.023	-0.025
Écart-type	1.573	3.417	0.030	0.009	0.014
Δ					
Moyenne $\Delta_{agent-TWAP}$	67.220	28.871	0.028	0.028	0.028
Moyenne $\Delta_{agent-AC}$	67.214	0.301	0.018	0.028	0.027
Écart-type $\Delta_{agent-TWAP}$	4273.461	1611.462	0.004	0.004	0.009
Écart-type $\Delta_{agent-AC}$	4273.461	14.673	0.011	0.006	0.010
Nombre d'épisodes					
Agent bat TWAP	3997	6001	2216	9318	9848
Agent bat AC	3970	5971	2176	9317	9839
TWAP bat Agent	49	1	2	42	183
AC bat Agent	76	31	42	43	191
Gain-Perte					
Moyenne gain (Agent bat TWAP)	68.044	28.890	0.028	0.029	0.029
Moyenne gain (Agent bat AC)	68.501	0.302	0.018	0.028	0.028
Moyenne perte (TWAP bat Agent)	0.006	0.004	0.004	0.004	0.013
Moyenne perte (AC bat Agent)	0.006	0.002	0.003	0.004	0.013
GLR					
GLR TWAP	12142.232	6950.423	7.409	7.907	2.158
GLR AC	10838.338	171.941	5.645	7.707	2.163

TABLE 3.4 – Comparaison des performances

On peut constater d'abord que l'agent PPO+LSTM surpasse les modèles TWAP et AC mais a obtenue en moyenne une récompense rentable uniquement sur le titre *GOOL* tout en gardant un écart-type faible, ce qui méritent beaucoup plus d'analyse pour une application réelle. Il faut aussi noter que la différence des récompenses par épisode entre l'agent PPO+LSTM et les modèles TWAP et AC est en moyen faible sur les données des titres *GOOGL*, *INTC* et *MSFT* mais reste très élevée sur les autres titres. De plus les ratios GLR élevés montrent que ces gains moyens obtenus lorsque l'agent PPO+LSTM domine TWAP et AC sont très supérieurs aux rares épisodes où il est moins performant.

Conclusion: Dans ce chapitre nous avons montré que le problème d'exécution optimale peut se formuler comme un processus de décision markovien qui contient les caractéristique de microstructures du marché. Ceci nous a permis de construire un environnement dans lequel l'agent *PPO+LSTM* a pu apprendre la dynamique du marché et ainsi prendre des décisions grâce à des interactions avec cet environnement. L'analyse de résultats montre que l'agent à exploiter l'information contenue dans le carnet d'ordres pour adapter ses stratégies, ce qui lui permet de surpasser les stratégies du modèle de référence *Almgren-Chriss* avec différents niveaux d'aversion au risque. Ces résultats montrent ainsi l'intérêt de l'apprentissage par renforcement pour le problème d'exécution optimale. Contrairement aux approches reposant sur des hypothèses simples, l'agent *PPO+LSTM* est capable d'exploiter directement les données de marché et d'adapter ses stratégies.

Ce travail pourra se poursuivre à l'analyse de la sensibilité et de la robustesse du modèle *PPO+LSTM*, qui consiste à analyser les résultats lorsque différents paramètres du modèle et de l'environnement varient.

CONCLUSION

Ce mémoire nous a permis de mettre en évidence l'intérêt de combiner les données de microstructure des marchés financiers avec les techniques d'apprentissage par renforcement pour concevoir des stratégies d'exécution capables de s'adapter à la dynamique du marché. Ceci s'est fait grâce à une présentation des fondements théoriques du modèle d'*optimisation de politique proximale* qui fait partie des méthodes de gradient de politique qui alterne entre l'échantillonnage des données et l'interaction avec l'environnement. Il s'agit d'un cadre qui offre l'avantage à un agent d'apprendre directement à partir des interactions avec son environnement sans nécessiter d'hypothèses fortes sur celui-ci. Ensuite ce modèle a été déployé sur des données de carnet d'ordre du NASDAQ datant du 21 juin 2012 et comparé au modèle d'*Almgren-Chriss* qui est un modèle de référence en exécution optimale. L'analyse des performances a montré que le modèle *optimisation de politique proximale* surpasse globalement le modèle d'*Almgren-Chriss*, prouvant ainsi qu'un agent d'*optimisation de politique proximale* est capable d'exploiter efficacement l'information contenue dans le carnet d'ordres et d'adapter sa stratégie aux caractéristiques de microstructure du marché de chaque titre financier.

Cependant, Plusieurs adaptations peuvent être faites pour accroître les performances générales du modèles. Dans notre travail les expériences ont été réalisées sur des données financières d'une période d'une heure, ce qui est relativement court, et sur un nombre limité de titres financiers. Des travaux futurs pourraient étendre cette étude à des horizons temporels plus longs, intégrer beaucoup plus de variables de microstructures du marché, permettre aussi à l'agent de soumettre des ordres à cours limité et même prendre en compte plusieurs actifs simultanément. De plus, il serait intéressant de déployer ce modèle sur un marché en temps réel afin que ses actions soient aussi analysées par d'autres acteurs du marché, ou encore le comparer à des approches plus récentes telles que des architectures basées sur les Transformers.

Bibliographie

- [1] [Almgren and Chriss, 2000] Robert Almgren and Neil Chriss : *Optimal execution of portfolio transactions*. Journal of Risk, 3 :5–40, 2000. <https://www.smallake.kr/wp-content/uploads/2016/03/optliq.pdf>
- [2] Andre F Perold : *The implementation shortfall : Paper versus reality*. Journal of Portfolio Management, 14, no. 3 (spring 1988) : 4–9
- [3] Bertsimas, D. and A. W. Lo : *Optimal control of liquidation costs*. Journal of Financial Markets 1 (1998) 1—50. <https://www.mit.edu/~dbertsim/papers/Finance/Optimal%20control%20of%20execution%20costs.pdf>
- [4] Fonds monétaire international : *Manuel de Statistiques Monétaires et Financières*, 2000 <https://www.imf.org/external/pubs/ft/mfs/manual/fra/pdf/mfsmch1f.pdf>
- [5] Franck Vandewiele, Samuel Delepoulle. *Méthodes d'apprentissage par renforcement pour espaces continus : les méthodes à gradient de politique et leurs améliorations (TRPO et PPO)*. v1.01. Laboratoire d'Informatique Signal et Image de la Côte d'Opale. 2023. ⟨hal-04115352⟩. <https://hal.science/hal-04115352v1>
- [6] Kakade, Sham and Langford, John. *Approximately optimal approximate reinforcement learning*. In ICML, volume 2, pp. 267–274, 2002. <https://people.eecs.berkeley.edu/~pabbeel/cs287-fa09/readings/KakadeLangford-icml2002.pdf>
- [7] [Lin and Beling, 2021] Siyu Lin and Peter A Beling : *An end-to-end optimal trade execution framework based on proximal policy optimization*. In Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence, pages 4548– 4554, 2021. <https://www.ijcai.org/proceedings/2020/0627.pdf>
- [8] Martin D. Gould, Masone Porter : *Limit order books*, 2013 <https://www.math.ucla.edu/~mason/papers/gould-qf-final.pdf>
- [9] Maureen O'Hara : *Market Microstructure Theory*, 1998 https://www.google.be/books/edition/Market_Microstructure_Theory/D-PGBwAAQBAJ?hl=fr&gbpv=1&dq=Maureen+O%E2%80%99Hara:+Market+Microstructure+Theory&printsec=frontcover
- [10] Mnih et al. *Playing Atari with Deep Reinforcement Learning*, DeepMind, 2015.
- [11] Ning, B., Ling, F. H. T., and Jaimungal, S. *Double Deep Q-Learning for Optimal Execution*, 2018. <https://arxiv.org/abs/1812.06600>
- [12] Olivier Guéant : *The financial mathematics of market liquidity, from optimal execution to market making*, 2016
- [13] Robert Kissell : *The Science of Algorithmic Trading and Portfolio Management*, 2013 https://www.google.be/books/edition/The_Science_of_Algorithmic_Trading_and_P/FKPND2zz90oC?hl=fr&gbpv=1&dq=The+Science+of+Algorithmic+Trading+and+Portfolio+Management&printsec=frontcover
- [14] SCHULMAN, J., WOLSKI, F., DHARIWAL, P., RADFORD, A. and KLIMOV, O. *Proximal Policy Optimization Algorithms*, 2017. <https://arxiv.org/abs/1707.06347>, <https://spinningup.openai.com/en/latest/algorithms/ppo.html>
- [15] SUTTON R. and BARTO, A. G. *Reinforcement Learning : An Introduction (Second)*, 2018. The MIT Press. <http://incompleteideas.net/book/the-book-2nd.html>

- [16] C. J. C. H. Watkins and P. Dayan. *Q-learning*, Machine Learning, 8 (1992), pp. 279-292. <https://link.springer.com/article/10.1007/BF00992698>